

UJIAN AKHIR SEMESTER BENGKEL KODING DATA SCIENCE

A. Latar Belakang

Churn pelanggan adalah kondisi ketika seorang pelanggan berhenti menggunakan layanan atau tidak lagi melakukan aktivitas pembelian. Masalah ini sangat penting dalam bidang bisnis dan pemasaran karena tingkat churn yang tinggi dapat menurunkan pendapatan perusahaan serta meningkatkan biaya untuk mendapatkan pelanggan baru. Oleh karena itu, kemampuan memprediksi pelanggan mana yang berpotensi churn menjadi hal yang sangat dibutuhkan.

Dataset *Sales and Marketing Customer* berisi informasi tentang pelanggan, seperti data demografis, aktivitas penggunaan layanan, riwayat transaksi, serta interaksi pelanggan dengan perusahaan. Tujuan utama dataset ini adalah untuk memprediksi apakah seorang pelanggan akan churn atau tidak melalui target **Churn**, yang berisi dua nilai: 1 (pelanggan berhenti menggunakan layanan) dan 0 (pelanggan tetap menggunakan layanan). Dalam proyek UAS ini, Anda berperan sebagai Data Scientist yang membangun model prediksi *churn* menggunakan model machine learning serta melakukan deployment pada model terbaik yang dibangun.

B. Dataset

1. Sumber data awal: Sales and Marketing Dataset
2. Link: <https://www.kaggle.com/datasets/bhaskerpaul/sales-and-marketing-dataset>
3. Karakteristik dataset:

No	Kolom	Tipe	Keterangan Singkat
1	customer_id	int64	ID unik setiap pelanggan
2	gender	object	Jenis kelamin pelanggan
3	age	float64	Usia pelanggan
4	country	object	Negara asal pelanggan
5	city	object	Kota pelanggan
6	signup_date	object (datetime)	Tanggal pelanggan mendaftar

7	last_purchase_date	object (datetime)	Tanggal transaksi terakhir pelanggan
8	acquisition_channel	object	Sumber pelanggan (Email, Ads, dll)
9	device_type	object	Jenis perangkat yang digunakan
10	subscription_type	object	Jenis langganan pelanggan
11	is_premium_user	int64	Status pengguna premium (0 = tidak, 1 = ya)
12	total_visits	int64	Total kunjungan pelanggan
13	avg_session_time	float64	Rata-rata waktu sesi penggunaan
14	pages_per_session	float64	Rata-rata halaman per sesi
15	email_open_rate	float64	Persentase email yang dibuka
16	email_click_rate	float64	Persentase klik pada email
17	total_spent	float64	Total pengeluaran pelanggan
18	avg_order_value	float64	Rata-rata nilai transaksi
19	discount_used	int64	Penggunaan diskon (0 = tidak, 1 = ya)
20	coupon_code	object	Kode kupon yang digunakan
21	support_tickets	int64	Jumlah tiket dukungan pelanggan
22	refund_requested	int64	Permintaan refund (0 = tidak, 1 = ya)
23	delivery_delay_days	int64	Keterlambatan pengiriman (hari)
24	payment_method	object	Metode pembayaran
25	satisfaction_score	float64	Skor kepuasan pelanggan
26	nps_score	int64	Net Promoter Score pelanggan
27	marketing_spend_per_user	float64	Biaya pemasaran per pelanggan
28	lifetime_value	float64	Nilai total pelanggan selama berlangganan

29	last_3_month_purchase_freq	int64	Frekuensi pembelian 3 bulan terakhir
30	churn	int64	Variabel target: status churn (0 = tidak, 1 = ya)

4. Jumlah sampel data: 15.000 records.

C. Tujuan Proyek

1. Melakukan eksplorasi data (EDA) yang komprehensif untuk memahami hubungan antara biaya iklan di berbagai platform (TV, Radio, Social Media) dengan volume penjualan, serta mengidentifikasi pola distribusi dan korelasi antar variabel pemasaran.
2. Melakukan pelatihan model pada tiga kategori model *machine learning*, yaitu model konvensional, *ensemble bagging*, dan *ensemble voting*. Pilih salah satu model dari setiap kategori untuk digunakan dalam pemodelan prediksi churn.
3. Mengevaluasi performa setiap model melalui 3 skenario eksperimen, yaitu penggunaan model secara langsung tanpa pemrosesan (*direct*), penerapan preprocessing (seperti *scaling* atau *encoding*), serta pengoptimalan model dengan hyperparameter tuning.
4. Menghasilkan total 9 model dari kombinasi tiga kategori model dan tiga skenario eksperimen, kemudian mengevaluasi performanya menggunakan metrik klasifikasi seperti accuracy, precision, recall, F1-score, dan confusion matrix.
5. Menganalisis dan membandingkan kinerja model pada setiap skenario untuk mengidentifikasi model terbaik, kemudian melakukan deployment terhadap model yang memiliki performa prediksi churn paling optimal.

D. Poin Penugasan

1. EDA

Unit Kompetensi: Mengolah data dan memvalidasi data.

Tugas:

1. Menampilkan 5 baris pertama, informasi dataset, dan statistik deskriptif.
2. Menghitung persentase nilai kosong (*missing value*) untuk semua kolom dan visualisasikan hasilnya dalam bentuk diagram batang.

3. Memvisualisasikan distribusi variabel target (*Churn*) untuk mengetahui kondisi keseimbangan kelas menggunakan diagram batang.
4. Membuat heatmap korelasi untuk fitur numerik dalam dataset dan identifikasi hubungan antar variabel yang berpotensi mempengaruhi pola *churn* pelanggan.

2. Direct Modeling

Unit Kompetensi: Membangun model dasar dan menghasilkan prediksi awal.

Tugas:

1. Menetapkan variabel target (*y*) yaitu kolom *Churn*, serta menggunakan seluruh kolom lain sebagai fitur prediktor (*X*).
2. Melakukan *train-test split* untuk membagi data menjadi data latih dan data uji.
3. Memilih tiga model yang mewakili setiap kategori, yaitu satu model konvensional (misalnya Logistic Regression atau KNN), satu model *ensemble bagging* (misalnya Random Forest), dan satu model yang merupakan gabungan beberapa model konvensional (misalnya kombinasi Logistic Regression, SVM, dan KNN dalam VotingClassifier).
4. Melatih ketiga model tersebut secara langsung tanpa preprocessing dan tanpa hyperparameter tuning.
5. Mengevaluasi performa model menggunakan matrix accuracy, precision, recall, F1-score, serta menyajikan confusion matrix.

2. Modeling Dengan Preprocessing

Unit Kompetensi: Membangun model dan menghasilkan prediksi dengan data yang bersih.

Tugas:

1. Melakukan preprocessing data, yang mencakup:
 - Penanganan missing value, duplikasi, dan outlier.
 - Encoding untuk fitur kategorikal.
 - Scaling fitur jika diperlukan. **Scaling dilakukan setelah data splitting.**
 - Penghapusan atau penyesuaian fitur yang dianggap tidak relevan berdasarkan analisis awal.
2. Menetapkan kembali fitur prediktor (*X*) dan variabel target (*y*) setelah seluruh tahap *preprocessing* diterapkan.

3. Melakukan *train-test split* dengan proporsi yang sama seperti pada skenario *direct modeling*.
4. Melatih ketiga model yang dipilih kembali menggunakan data hasil *preprocessing* tanpa melakukan *hyperparameter tuning*.
5. Mengevaluasi performa model menggunakan metrik evaluasi seperti *accuracy*, *precision*, *recall*, *F1-score*, serta menyajikan *confusion matrix*.

3. Hyperparameter Tuning dan Feature Selection

Unit Kompetensi: Mengoptimalkan kinerja model melalui *hyperparameter tuning*.

Tugas:

1. Melakukan analisis *feature importance* pada data untuk menentukan fitur mana yang paling berpengaruh.
2. Menyusun parameter grid atau ruang pencarian hyperparameter yang sesuai untuk masing-masing model.
3. Melakukan proses *hyperparameter tuning* menggunakan metode seperti GridSearchCV, RandomizedSearchCV, atau metode lain yang relevan.
4. Memperoleh *best estimator* beserta *best parameters* dari hasil tuning.
5. Melatih kembali *best estimator* menggunakan data latih untuk menghasilkan model dengan konfigurasi optimal.
6. Mengevaluasi performa model yang optimal menggunakan metrik evaluasi seperti *accuracy*, *precision*, *recall*, *F1-score*, serta menyajikan *confusion matrix*.

4. Deployment

Unit Kompetensi: Mendeploy model terbaik ke streamlit cloud.


Tugas :

1. Menyiapkan model terbaik yang telah diperoleh dari proses evaluasi dan *hyperparameter tuning*.
2. Menyimpan model terbaik dalam format yang sesuai (misalnya .pkl atau .joblib) agar dapat dimuat di aplikasi Streamlit.
3. Membuat aplikasi Streamlit yang berisi:
 - Pemuatan model,
 - Form atau input fitur,
 - Proses prediksi,
 - Tampilan hasil prediksi,



PROGRAM KEGIATAN
BENGKEL KODING
UNIVERSITAS DIAN NUSWANTORO

Jl. Imam Bonjol No.207 (Gedung H, Lantai 7) UDINUS Semarang, Telp. (024) 3569196
Homepage : <https://bengkelkoding.dinus.ac.id/> E-mail : sekretariat@fasilkom.dinus.ac.id



- Serta elemen pendukung lain (penjelasan fitur, visualisasi, dsb.).
- 4. Melakukan development lokal untuk memastikan aplikasi dapat berjalan dengan baik sebelum deployment.
- 5. Menyiapkan file pendukung seperti requirements.txt agar Streamlit Cloud dapat menginstal dependensi yang diperlukan.
- 6. Mengunggah proyek ke GitHub atau repositori lain yang didukung sebagai sumber kode bagi Streamlit Cloud.
- 7. Melakukan deployment aplikasi ke Streamlit Cloud, lalu memastikan aplikasi dapat diakses secara publik.

Mengetahui,

Koordinator Bengkel Koding